

Human Safety Monitoring System — Technical Report

INaI Competition 2026 × IT Del · AI Engineer Track · Domain 1: Human Safety Monitoring (Computer Vision)
William Panjaitan · github.com/20WilliamPanjaitan/Human-Safety-Monitoring-System · Juni 2026

1. Problem & Scope

Sistem monitoring keselamatan manusia berbasis kamera untuk area konstruksi. Diimplementasikan **4 dari 5** modul (minimum 3): **person detection**, **person tracking**, **PPE detection** (helmet/vest/mask), dan **people counting**. Face recognition sengaja tidak diimplementasi (privacy/PDP-by-design + batas waktu). Satu model **YOLOv8s multi-class (7 kelas)** menggerakkan semua modul, disajikan lewat **inference endpoint FastAPI** (ONNX Runtime untuk gambar, PyTorch untuk tracking) dan dashboard Streamlit. Target metrik $mAP@0.5 \geq 0.50$ (go/no-go) — tercapai **0.78**.

2. Data

Dataset **Construction Site Safety** (Roboflow Universe, lisensi **CC BY 4.0**). 10 kelas asli di-remap ke 7 kelas relevan (*Person*, *Hardhat*, *NO-Hardhat*, *Safety-Vest*, *NO-Safety-Vest*, *Mask*, *NO-Mask*) via `remap_labels.py`; kelas *Safety-Cone/machinery/vehicle* dibuang. Split memakai bawaan Roboflow **2605/114/82** (train/val/test). Kebocoran diaudit **2 lapis** (`check_leakage.py`): **0 duplikat byte-identik (MD5)** antar split; namun **19 scene video tersebar antar split** (frame dari klip sama ada di train & test) → mAP test sedikit optimistis. Dilaporkan jujur sebagai limitasi, bukan di-*re-split* (yang akan memaksa re-training di window 22,5 jam). Ketujuh kelas muncul di split test; label diverifikasi visual (`sanity_check.py`).

3. Model & Training

YOLOv8s (Ultralytics 8.3.0), transfer-learning dari bobot COCO. Dilatih di Google Colab **Tesla T4, 50 epoch**, `imgsz 640`, `batch 16`, **seed 42** (`random/numpy/torch + cudnn.deterministic`). Augmentasi: `mosaic + close_mosaic=10`, `HSV jitter (h .015/s .7/v .4)`, `scale .5`, `translate .1`, `flipplr .5`, `flipud 0`. Bobot final `weights/best.pt` (MD5 `2bdce55a...`), diekspor ke **ONNX** untuk inference CPU yang lebih ringan; parity deteksi ONNX↔PT terverifikasi (5/5 identik kelas+conf@2dp). Provenans lengkap di `report/MODEL_PROVENANCE.md` (termasuk run lokal 5-epoch yang di-abort & dibuang).


4. Evaluation

Eval reproducible (`eval.py`, seed 42, hasil identik antar-run) pada split test:

	mAP@0.5	mAP@0.5:0.95	Precision	Recall
	0.778	0.456	0.883	0.733

Kelas	Person	Hardhat	NO-Hardhat	Safety-Vest	NO-Safety-Vest	Mask	NO-Mask
AP@0.5	0.843	0.879	0.562	0.857	0.786	0.761	0.755

Kenapa mAP, bukan accuracy? Deteksi tak punya "accuracy" tunggal: tiap gambar punya jumlah objek berbeda dan kualitas lokalisasi (IoU) penting. mAP mengintegrasikan kurva precision–recall lintas ambang confidence dan IoU per kelas — menangkap *missed detection* dan *false alarm* sekaligus. Accuracy (benar/total) tak terdefinisi untuk jumlah box yang variabel dan akan menutupi ketimpangan kelas (mis. kelas NO-* yang jarang). **Insight confusion matrix** (ternormalisasi): *Hardhat↔NO-Hardhat* nyaris tak pernah tertukar (silang 0.02) — saat model bilang "no-helmet", jarang itu false alarm; error dominan adalah *miss→background* (Person 0.35, NO-Hardhat 0.44), yaitu under-deteksi objek kecil/jarang, **bukan** salah klasifikasi safety-critical. Ini mode kegagalan yang diinginkan auditor: cenderung "kelewat deteksi", bukan "keliru menyatakan patuh padahal melanggar".



Gambar 1. Confusion matrix ternormalisasi (split test).

5. System Design

Satu core bersama (app/) dipakai identik oleh REST API dan UI:

- **Detector**: wrapper YOLOv8 (ONNX/PT), di-load sekali, *lazy* saat request pertama (startup ringan).
- **PPE logic**: asosiasi PPE↔person via **containment** (fraksi box PPE di dalam box orang), **bukan IoU** — IoU gagal untuk PPE kecil vs box orang yang tinggi. Vonis pakai **bukti positif kelas negatif** (NO-Hardhat/NO-Safety-Vest): status 3-nilai *ok/violation/unknown*. *violation* butuh

box NO-* yang overlap; sekadar PPE tak terdeteksi → *unknown* (hindari pelanggaran palsu). Wajib = helmet+vest; mask dipantau, tak wajib. Multiple-violation + **severity** (none/low/high) + agregat `summarize()` per-frame (Extraordinary 1).

- **Tracking:** **ByteTrack** (Ultralytics), tuned (`track_buffer=60` utk okulasi singkat, `match_thresh=0.85` kurangi ID-switch); ID stabil antar-frame, jumlah ID unik = people counting versi video.
- **Counting:** per-gambar (jumlah box) & per-video (`track_id` unik).

API (FastAPI): `/health /detect /ppe /count /track /annotate`, tiap respons memuat `latency_ms`, error handling 400/415/500. **Latency** (CPU lokal): detect ~114 ms, ppe ~116 ms (p50, <500 ms target); track klip 9,6 dtk → 8,8 dtk (`vid_stride 2`, `imgsz 480`). **Visualisasi:** `/annotate` menggambar box berwarna-kepatuhan (hijau patuh / merah pelanggaran / kuning unverified) + label kelas&conf; dashboard Streamlit menambah UI interaktif termasuk tab *Robustness Test*. **Deployment:** dikemas Docker (torch CPU-only) dan di-deploy ke **Railway** sebagai endpoint publik HTTPS (URL di README); `smoke_test.py` memvalidasi semua endpoint + error-case.

6. AI Usage Log

Tools. Claude Code (Anthropic, **Opus 4.8**) — asisten coding agentic; Ultralytics YOLOv8 **8.3.0** (train/inference/val); ByteTrack (built-in Ultralytics). **Tidak** ada synthetic data atau golden eval hasil LLM (semua metrik dari training/eval nyata), jadi aturan review 30% tak berlaku.

Pola. Agentic/multi-step: scaffolding, generate kode, debugging, refactor ke production-quality — tiap perubahan di-review & diverifikasi manual. **Prompt utama Fase 2:** (i) bangun dashboard Streamlit modern di atas modul yang ada; (ii) jalankan uji edge-case Tahap 7 + generate aset/laporan; (iii) integrasikan edge-case sebagai tab Robustness di UI; (iv) uji tab di browser nyata; (v) analisis repo → dokumen struktur per-file; (vi) audit kelengkapan vs rubrik; (vii) siapkan deployment Docker (Render→Railway) & perbaiki kegagalan ABI cv2/NumPy; (viii) tulis report ini. **Verifikasi & judgment:** menolak/menyesuaikan saran AI — mendiagnosis mismatch opencv-headless 4.10 vs NumPy 1.x lalu pin 4.9.0.80; memperbaiki Streamlit `use_container_width`→`use_column_width` (v1.37). Semua kode dijalankan & diuji (`ppe_demo.py` 8/8 unit, `smoke_test.py` semua endpoint PASS, eval reproducible). History prompt lengkap di `AI_USAGE_LOG.md`.

7. Limitations (disadari)

- **Scene leakage:** 19 scene video tersebar antar split → mAP test sedikit optimistis (diukur & diungkap).
- **Kelas negatif jarang:** NO-Mask/NO-Hardhat recall terendah (instance sedikit, objek kecil) — diagonal confusion NO-Mask 0.39.
- **Asosiasi crowd:** 1 box PPE bisa di-claim >1 orang yang overlap (simplifikasi diterima); NMS padat bisa under-count.
- **Tanpa ReID sejati:** ByteTrack berbasis gerak (`track_buffer ≈ 2,4 dtk @25 fps`); ID bisa berubah setelah keluar-frame lama (>~3 dtk) — ReID appearance-embedding belum ada.
- **Robustness sintetis:** low-light = brightness global ↓ (model terbukti robust, kemungkinan dari HSV-value aug); noise/blur malam nyata belum diuji. Far/small menurunkan deteksi PPE (→ unverified, bukan pelanggaran palsu).
- **Tanpa face recognition:** sengaja di-descope demi privacy/PDP-by-design & waktu; alerting berbasis identitas di luar scope.
- **Compute free-tier:** CPU-only; /track klip panjang berat memori (demo pakai klip pendek); ada cold-start pada request pertama.